

License Plate Recognition e Problema Fictício

Análise e interpretação de dados

Vitor Greati ¹ Vinicius Campos¹

¹Instituto Metrópole Digital
UFRN

Outubro, 2016

Conteúdo

1 License Plate Recognition

- Conceituação
- Etapas
- Dados disponibilizados
- Extração de descritores
- Análises estatísticas e tratamento dos descritores

2 Problema Fictício


- Descrição do problema
- Medidas de tendência central e distribuição
- Grau de normalidade, assimetria, curtose e correlação
- Resolução do problema

3 Bibliografia

Conceituação

Um sistema de *License Plate Recognition* (**LPR**) consiste em um *hardware* e um *software* integrados com o objetivo de reconhecer placas de veículos a partir de imagens [1].

Ou seja, o sistema recebe uma imagem e retorna o conteúdo da placa, se ela existir:



Aplicabilidade

Sistemas LPR são comumente aplicados em:

- Segurança de áreas restritas;
- Emissão de bilhetes em estacionamentos;
- Vrl - Vehicle re-Identification;
- Identificação de modelo e fabricante.

Conteúdo

1 License Plate Recognition

- Conceituação
- **Etapas**
- Dados disponibilizados
- Extração de descritores
- Análises estatísticas e tratamento dos descritores

2 Problema Fictício

- Descrição do problema
- Medidas de tendência central e distribuição
- Grau de normalidade, assimetria, curtose e correlação
- Resolução do problema

3 Bibliografia

Etapas

Um sistema LPR implementa geralmente as seguintes etapas:

- 1 Aquisição da imagem;
- 2 Detecção da placa;
- 3 Segmentação dos caracteres;
- 4 Reconhecimento ótico dos caracteres.

Aquisição da imagem e detecção da placa

- Todo o processo se inicia com a obtenção da imagem por **câmeras e sensores adicionais**, adequadamente **calibrados** para o ambiente de utilização;
- Essa imagem compreende partes do ambiente, partes do veículo, além de outros **ruídos**. Por essa razão, faz-se necessária a etapa de **detecção da placa**, baseada essencialmente em técnicas de Processamento de Imagens.



Segmentação de caracteres

- Com a placa em mãos, o próximo passo é a **obtenção de cada caractere separadamente**;
- Para tanto, pode ser necessária uma etapa de pré-processamento, para normalizar a imagem, remover ruídos e acentuar características importantes;
- As projeções horizontal e vertical são técnicas muito utilizadas nesse processo.



Reconhecimento ótico de caracteres

- Dado um caractere segmentado, resta **classificá-lo** em uma das 36 classes possíveis (26 letras + 10 dígitos);
- Entre as principais técnicas, as redes neurais e os classificadores estatísticos têm se destacado;
- Os resultados desta fase compõem a **saída do sistema**: um conjunto de caracteres ASCII correspondentes ao conteúdo da placa.

F

Q

Conteúdo

1 License Plate Recognition

- Conceituação
- Etapas
- **Dados disponibilizados**
- Extração de descritores
- Análises estatísticas e tratamento dos descritores

2 Problema Fictício

- Descrição do problema
- Medidas de tendência central e distribuição
- Grau de normalidade, assimetria, curtose e correlação
- Resolução do problema

3 Bibliografia

Caracterização dos dados fornecidos

- São caracteres já segmentados de imagens capturadas em 11 locais diferentes da UFRJ [2];
- Cada classe (letra) possui aproximadamente 600 instâncias, ou seja, é garantido o **balanceamento**;
- Os dados estão organizados em uma matriz $M_{11 \times 26}$ de vetores de *structs* contendo os campos:
 - `bmp_data` Três matrizes iguais de dimensão 16×16 , representando a imagem do caractere em tons de cinza;
 - `target_char` A classe à qual a imagem pertence;
 - `target` O índice dessa classe;
 - `local` Índice do local de origem.

Separação das amostras

Para a tarefa de classificação, é importante a separação da massa de dados em conjuntos de **treino**, **testes** e **validação**. Neste trabalho, foi escolhida a seguinte configuração de amostras:

Treino	Testes	Validação
60%	25%	15%

Para obtê-las, um *script* em Octave/MATLAB foi criado, buscando garantir a **representatividade** quanto às letras e aos locais de obtenção.

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - **Extração de descritores**
 - Análises estatísticas e tratamento dos descritores
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Mapa de bits com projeções

A técnica adotada foi a de **mapa de bits com projeções**, a qual resulta em um vetor com os valores dos pixels normalizados mais as projeções horizontal e vertical, como resumido na tabela abaixo:

Descritores	Tipo	Valores	Passos da Extração
$N \times N$ pixels	Numérico	$[0, 1]$	Moldura, normalização, complemento
Projeção horizontal (N)	Numérico	Inteiros	Binarização, soma das linhas
Projeção vertical (N)	Numérico	Inteiros	Binarização, soma das colunas



Neste caso, $N = 14$, totalizando **224 descritores** à princípio.

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - Extração de descritores
 - **Análises estatísticas e tratamento dos descritores**
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Da normalidade dos dados

Os *q-q plots* revelaram o que já era esperado, pela natureza do problema: os descritores não obedecem, em geral, à distribuição normal.



Esse fato torna desnecessárias as análises de curtose e assimetria.

Média e variância

- Observou-se que 34 dos descritores ligados aos pixels possuem média abaixo de 10^{-2} , o que pode indicar que são pixels de *background*;
- Desses, 29 possuem variância menor que 0.005^1 , mostrando que possuem baixa dispersão e que podem ser eliminados. Abaixo está uma representação deles:




Figura : Vermelho: variância ≤ 0.005 ; Vermelho + Laranja: variância ≤ 0.01

¹A média das variâncias é 0.07

Correlação e descorrelação

A matriz de correlação indicou que **pixels vizinhos estão mais correlacionados**, e positivamente, o que é observável comparando-se as imagens:



Havendo tal redundância, a descorrelação foi feita pela multiplicação da matriz de dados pela de autovetores da matriz de covariâncias, T .

Conclusões

- A normalidade dos descritores, por não se fazer presente, não pode ser ferramenta imediata para a classificação;
- É possível reduzir a dimensionalidade do problema com base apenas na variância de certos descritores;
- A vizinhança dos pixels provoca uma maior correlação e, portanto, redundância de informação.

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - Extração de descritores
 - Análises estatísticas e tratamento dos descritores
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Descrição do problema

O problema consiste em um conjunto de dados de dimensão 6 com 150 instâncias, ou seja, é uma matriz 150×6 . As seis variáveis estão relacionadas a três targets, A, B e C, e se encontram distribuídas desta forma:

- **Linhas 1 a 50:** Target A;
- **Linhas 51 a 100:** Target B;
- **Linhas 101 a 150:** Target C.

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - Extração de descritores
 - Análises estatísticas e tratamento dos descritores
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Medidas de tendência central

Variáveis	V1	V2	V3	V4	V5	V6
Médias	-1.4572e-15	-1.6383e-15	-1.2923e-15	-5.5437e-16	1.6017e-15	3.0790e-16

Tabela : Média aritmética

Variáveis	V1	V2	V3	V4	V5	V6
Medianas	-0.052331	-0.131539	0.335354	0.132067	-0.259902	-0.444690

Tabela : Mediana

Variáveis	V1	V2	V3	V4	V5	V6
Modas	-1.01844	-0.13154	-1.33575	-1.31105	-0.53542	-0.44469

Tabela : Moda

Medidas de distribuição

Variáveis	V1	V2	V3	V4	V5	V6
Desvios absolutos médios	0.83031	0.77267	0.88526	0.86342	0.85385	0.87463

Tabela : Desvio absoluto médio

Variáveis	V1	V2	V3	V4	V5	V6
Variâncias	1	1	1	1	1	1

Tabela : Variância

Variáveis	V1	V2	V3	V4	V5	V6
Desvios padrões	1	1	1	1	1	1

Tabela : Desvio padrão

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - Extração de descritores
 - Análises estatísticas e tratamento dos descritores
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Grau de normalidade




Figura : Q-Q Plot V1




Figura : Q-Q Plot V2




Figura : Q-Q Plot V3




Figura : Q-Q Plot V4




Figura : Q-Q Plot V5




Figura : Q-Q Plot V6

Grau de assimetria e curtose

Variável	\bar{x}	x_{mo}	s	AS	Assimetria
V1	-1.4572e-15	-1.0184e+00	1.0000e+00	1.01844e+00	positiva
V2	-1.6383e-15	-1.3154e-01	1.0000e+00	1.3154e-01	negativa
V3	-1.2923e-15	-1.3358e+00	1.0000e+00	1.3358e+00	positiva
V4	-5.5437e-16	-1.3111e+00	1.0000e+00	1.3111e+00	positiva
V5	1.6017e-15	-5.3542e-01	1.0000e+00	5.3542e-01	negativa

Tabela : Grau de assimetria

Variáveis	V1	V2	V3	V4	V5
Grau	2.4264	3.1810	1.6045	1.6639	2.1943

Tabela : Grau de curtose das variáveis

Grau de correlação

$$\begin{bmatrix}
 1.000000 & -0.117570 & 0.871754 & 0.817941 & -0.448685 & 0.136343 & 0.782561 \\
 -0.117570 & 1.000000 & -0.428440 & -0.366126 & 0.648175 & 0.079311 & -0.426658 \\
 0.871754 & -0.428440 & 1.000000 & 0.962865 & -0.828920 & 0.075906 & 0.949035 \\
 0.817941 & -0.366126 & 0.962865 & 1.000000 & -0.822567 & 0.088966 & 0.956547 \\
 -0.448685 & 0.648175 & -0.828920 & -0.822567 & 1.000000 & 0.016014 & -0.837950 \\
 0.136343 & 0.079311 & 0.075906 & 0.088966 & 0.016014 & 1.000000 & 0.104404 \\
 0.782561 & -0.426658 & 0.949035 & 0.956547 & -0.837950 & 0.104404 & 1.000000
 \end{bmatrix}$$

Descrição

A matriz acima representa a matriz de correlações das variáveis V1 à V6 (**normalizadas**) com *targets*. Substituíram-se os *targets* (*A,B,C*) pelos números (1,2,3), os quais foram incluídos em uma sétima coluna na matriz das variáveis normalizadas.

Conteúdo

- 1 License Plate Recognition
 - Conceituação
 - Etapas
 - Dados disponibilizados
 - Extração de descritores
 - Análises estatísticas e tratamento dos descritores
- 2 Problema Fictício
 - Descrição do problema
 - Medidas de tendência central e distribuição
 - Grau de normalidade, assimetria, curtose e correlação
 - Resolução do problema
- 3 Bibliografia

Resolução do problema - 1 variável




Figura : Plot V3




Figura : Plot V4

Análise

Ao analisar os gráficos, é possível perceber que as variáveis V3 e V4 podem solucionar o problema, pois conseguem delimitar as regiões de cada *target* com poucas sobreposições.

Resolução do problema - 2 variáveis

Análise

Neste caso, os pares de variáveis que podem resolver o problema são: $(V1, V3)$, $(V1, V4)$, $(V1, V5)$, $(V2, V3)$, $(V2, V4)$, $(V3, V4)$, $(V3, V5)$ e $(V4, V5)$.




Figura : Plot V1-V3




Figura : Plot V1-V4




Figura : Plot V1-V5




Figura : Plot V2-V3

Resolução do problema - 2 variáveis




Figura : Plot V2-V4




Figura : Plot V3-V4




Figura : Plot V3-V5




Figura : Plot V4-V5

Bibliografia



C.-N. E. Anagnostopoulos.

License plate recognition: A brief tutorial.

IEEE Intelligent Transportation Systems Magazine, 6(1):59 – 67, 2014.



A. A. Dieguez.

Reconhecimento de Caracteres de Placa Veicular Usando Redes Neurais.

Escola Politécnica – Departamento de Eletrônica e de Computação, 2010.